

AI 使用说明

姓名：郭嘉祺

学号：032402127

课程名称：数据分析与可视化

报告题目：福州二手房数据分析报告

使用工具：ChatGPT

1. 使用 AI 的基本情况

本次期末数据分析报告中，我使用了 GPT-5.5 Thinking 作为辅助工具。AI 在报告形成过程中参与较多，主要帮助我完成了以下几类工作：理解考试要求、搭建报告框架、解释代码报错、提供数据清洗思路、优化可视化图表、修改 Markdown 分析文字以及检查摘要和结论是否贴合数据结果。

本说明中的问答记录不是完整聊天截图，而是我根据实际交流过程整理出来的典型片段，用来说明 AI 在本次报告中具体起到了哪些作用，以及我如何对 AI 的输出进行判断和取舍。

2. AI 具体参与的环节

2.1 帮助理解考试要求，确定报告主线

刚开始写报告时，我知道需要完成数据读取、清洗、统计分析和可视化，但还不清楚整篇报告应该围绕什么问题展开。如果只是按步骤写，很容易变成“读取数据—画图—写结论”的流水账。因此，我先让 AI 根据考试要求和课程内容帮我梳理分析框架。

AI 给出的建议让我意识到，报告不能只展示代码，而应该围绕福州二手房市场本身提出问题。后来我把报告主线确定为“供给结构—价格差异—产品结构—板块溢价”，并据此安排 Notebook 的整体结构。

部分问答记录

我：

老师要求基于福州二手房数据写一份数据分析报告。请你仔细阅读撰写要求，严格按照考试要求，依据

我刚刚发给你的课程内容，你不需要给我完整的数据分析报告，而是整理一个清晰且能出彩的分析操作框架。

ChatGPT:

可以把主题设计为“基于福州二手房房源数据的市场供给结构、价格差异与影响因素分析”。报告不要只停留在查看数据和画图，而应围绕几个核心问题展开：哪些区域房源最多，哪些区域价格更高，不同户型、面积、房龄、板块对总价和均价有什么影响，是否存在高价房源或异常房源。

我后来的处理:

我按照考试要求，把 Notebook 安排为摘要、数据来源、数据读取、质量检查、数据清洗、描述性统计、可视化分析和主要结论八个部分。后续分析重点放在区域、户型、面积、板块和房龄这几个能够支撑结论的维度上。

2.2 帮助解决代码报错和 Notebook 执行顺序问题

在写 Notebook 的过程中，我遇到过一些具体报错。比较典型的是构造面积段时报 `KeyError: '面积_m²'`。一开始我以为是分箱代码本身写错了，但 AI 提醒我先检查当前数据框中是否真的存在这个字段。后来发现，问题主要出在前面的字段提取代码没有按顺序重新运行。

这次报错让我意识到，Jupyter Notebook 中单元格的显示顺序和实际执行顺序不一定一致。最后提交前，不能只看某些单元格曾经运行成功，而需要从头到尾重新运行一次。

部分问答记录

我:

5.8 代码报错了，提示 `KeyError: '面积_m²'`，我前面不是已经生成这个字段了吗？

ChatGPT:

这个错误说明当前 `df_clean` 里没有叫 `面积_m²` 的列。常见原因不是分箱代码错，而是前面生成 `面积_m²` 的单元格没有运行，或者后面又执行了 `df_clean = df.copy()` 覆盖了新字段。你可以先运行 `[col for col in df_clean.columns if '面积' in col or '总价' in col]` 检查当前字段。

我后来的处理:

我检查后发现，当时 `df_clean` 里确实没有 `面积_m²`。之后我重新运行了文本字段清洗和数值提取代码，并删除了临时调试代码，保证最终 Notebook 中只保留正式的数据清洗流程。

2.3 辅助数据清洗和特征构造，但清洗依据由我确认

数据清洗部分，AI主要帮我梳理了从原始文本字段提取变量的思路。因为老师要求中鼓励从CSV原始字段开始处理，所以我没有直接使用数据中已经整理好的面积数值、总价数值 和均价数值，而是重新从原始字段中提取变量。

我根据 AI的建议完成了以下处理：

- 从 面积 提取 面积_m²；
- 从 总价 提取 总价_万元；
- 从 均价 提取 均价_元每平；
- 从 户型 中提取 室、厅、卫，并构造 户型类别；
- 从 时间 中提取 建造年份，并计算 推算房龄；
- 从 所属区域 中提取 板块；
- 构造 面积段、总价段 和 区域圈层，用于后续分组分析。

这一部分我没有只看代码能不能运行，还检查了提取结果是否可靠。例如，我用`np.allclose()` 对比自己提取出的面积、总价和均价字段与原有数值列是否一致。发现价格字段有26条缺失后，我没有一开始就删除所有缺失记录，而是只在涉及总价和均价的分析中使用`df_price`。

2.4 辅助优化可视化图表，但最终图表经过多轮取舍

可视化部分是我和AI交流最多的部分。最开始AI给出的部分图表比较普通，比如简单柱状图、普通散点图和热力图。虽然这些图能展示数据，但我觉得不够美观，也没有很好地体现第七部分作为重点部分的分析价值，所以多次要求AI修改。

例如，最开始的“市区 × 户型类别”热力图信息比较密集，颜色和数字混在一起，看起来不舒服。我后来要求AI把它改成气泡矩阵，用颜色表示均价中位数，用气泡大小表示房源数量，这样既能看价格，也能看样本规模。再比如，面积段和总价段的热力图与前一张图形式重复，我要求AI改成100% 堆叠条形图，用来展示不同面积段内部的总价结构。

图表的最终取舍主要看三个标准：是否回答一个明确问题、是否和前面的图重复、是否能支撑报告结论。最后我保留了7张图，但每张图的作用不同：区域供给和价格定位、区域内部价格分布、面积与总价关系、户型和区域交叉差异、面积段内部总价结构、高价板块溢价率、房龄与区域圈层差异。

部分问答记录

我：

这两张图看起来好丑，而且第七部分里出现两张热力图，其中一张必须改掉形式。不能为了凑图，图必

须有用。

ChatGPT：

可以把“市区 × 户型类别”的热力图改成气泡矩阵图，颜色表示均价中位数，气泡大小表示房源数量。另一张“面积段 × 总价段”的热力图可以改成 100% 堆叠条形图，因为它本质上是在比较结构占比，堆叠图比热力图更合适。

我后来的处理：

我保留了这个修改方向，但继续调整了细节。气泡矩阵中，我没有让每个格子都强行标数字，而是控制了标注密度；面积段总价结构图中，我也只突出主要占比，避免图表过于拥挤。这样修改后，两张图的功能区分更清楚，一张强调区域和户型的价格差异，另一张强调面积段内部的总价结构。

2.5 辅助检查摘要和结论表达

报告最后，我先根据前面已经完成的统计表和图表，自己整理了摘要和主要结论的初稿。初稿中已经包含区域价格差异、面积与总价关系、板块溢价和房龄差异等内容，但有些表述比较直白，例如“主城区价格高于外围区县”“面积越大总价越高”。这些说法虽然和数据一致，但分析深度不够。

因此，我把自己的初稿和图表主要发现发给AI，请它帮我检查哪些表述比较空，哪些结论可以和数据对应得更紧。AI的建议不是替我重新生成结论，而是提醒我把表面现象改写成更有解释力的判断。。

部分问答记录

我：

我已经根据前面的统计表和图表写了摘要和主要结论，但感觉有些地方像“主城区更贵”“面积越大总价越高”这种太直白了。你帮我检查一下哪些表述比较空，怎么在不脱离数据的情况下写得更有分析味一点？

ChatGPT：

可以保留这些结论方向，但不要只写表面现象。比如“主城区更贵”可以结合供给强度和价格溢价矩阵，改成不同区域承担不同市场角色；“面积越大总价越高”可以结合相关性分析，说明面积对总价影响明显，但面积与均价相关性较弱，均价更可能受区域、板块等因素影响。

我后来的处理：

我把AI的建议当作检查清单，回到前面的图表逐条核对。能被统计结果和图表支持的表达才保留，例如“核心溢价型、供给主力型、外围低价型”“面积主要影响总价，但不足以解释均价差异”“高价差异下沉到板块层面”。不能和图表直接对应的泛泛表述，我就删掉或改弱。

3. 我对 AI 输出的检查和修改

3.1 检查是否符合老师要求

我在使用AI时一直对照老师的考试要求，特别关注是否完成了数据读取、字段说明、缺失值和重复值检查、数据清洗、分组统计、可视化和 Markdown 解释。AI有时会给出一些额外建议，但如果和考试要求关系不大，我没有放进最终报告。

3.2 检查代码能否从头运行

AI给出的代码都需要实际运行。遇到报错时，我会检查字段名、数据类型、变量是否提前定义，以及单元格是否按顺序执行。最后保留在报告中的代码，都经过运行验证。

3.3 检查统计结果是否支持文字结论

我没有让AI凭空写结论，而是先运行出表格或图表，再根据结果讨论文字表达。例如，写区域差异时参考各市区房源数量和均价中位数；写面积与价格关系时参考相关性矩阵和面积分箱趋势；写板块溢价时设置样本量门槛，避免样本太小导致结论不稳定。

3.4 修改模板化表达

AI有时会写出比较模板化的句子，例如“该图可以帮助我们进一步分析……”。我在最终报告中尽量把这类句子改成直接的分析判断，例如“鼓楼表现为低供给但高溢价”“面积主要影响总价，但不足以解释均价差异”“高价差异进一步体现在板块层面”。

4. 我认为自己独立完成和判断的部分

虽然AI在本次报告中发挥了较大作用，但以下部分是我根据数据结果和报告需要自己判断完成的。

4.1 分析重点的取舍

AI最初给出的分析角度很多，包括区域、户型、面积、房龄、楼层、朝向、板块等。最终我没有平均展开所有变量，而是把报告重点放在区域价格分化、产品结构和板块溢价上。楼层和朝向虽然完成了字段提取，但没有强行写进核心结论。

4.2 使用中位数作为主要价格比较指标

数据中存在总价3180万元、均价92968元/m²等高价房源。如果直接使用均值，容易被少数极端房源拉高。因此我在比较市区、户型和板块价格时，主要使用均价中位数和总价中位数。

4.3 不直接删除高价房源

高价房源可能是异常值，也可能代表核心地段、高端小区或大面积改善型房源。如果直接删除，可能会损失市场结构信息。因此我只在部分可视化中使用分位数过滤来提高图表可读性，没有在整体分析中简单删除高价房源。

4.4 从市区分析推进到板块分析

只看市区会得到比较普通的结论，例如鼓楼、台江价格较高。为了让分析更具体，我从所属区域中提取板块，并做了高价板块TOP15溢价率分析。这个结果帮助我把结论从“主城区更贵”推进到“具体板块存在更明显的溢价”。

4.5 对市场角色的判断

在区域供给强度与价格溢价矩阵中，我不是只比较哪个区房源多、哪个区价格高，而是把不同区域理解为不同市场角色。例如，鼓楼表现为低供给但高溢价，晋安表现为高供给且高溢价，仓山表现为高供给但价格相对平稳。这个判断是结合房源数量、价格中位数和图表位置后形成的。

5. 使用 AI 的反思

这次使用AI后，我感觉AI对完成数据分析报告确实有很大帮助。它可以帮我把零散的想法整理成框架，也能在代码报错和图表优化时提供比较快的反馈。特别是在可视化部分，我通过多次和AI讨论，把一些普通或不好看的图改成了更贴合分析问题的图。

但我也发现，AI的输出不能直接当成最终结果。有些回答会比较泛，有些图虽然代码正确但并不好看，有些结论如果不结合实际数据就会显得空。使用 AI 时，最重要的是自己要知道报告要分析什么、图表想说明什么、结论是否真的由数据支持。

所以这次我对AI的使用方式更像是“讨论和修改”，而不是让它一次性完成全部内容。AI提供了很多思路和技术帮助，但最终哪些内容进入报告、哪些图表保留、哪些结论可以成立，是我根据实际运行结果和老师的考试要求判断后确定的。